Physical AI 最終課題 中間レポート

SO101 片付けロボット:2カメラ化とデータ設計の改善

Oct 24, 2026 · ID:Y-ORIHARA

1. 概要

手首カメラを追加し、データの集め方を見直した結果、SO101 が**自律で黒いスポンジをつかみ、箱に入れることに成功**した。机の9か所で測った成功率は 13/29 回(45%)で、手前の列では 6/7 回(86%)だった。10月18日のモデルは、パーツのない場所へ手を伸ばして一度も成功しなかった(成功率の正式な計測は未実施)。

- **1個の片付け**:機に置いた黒いスポンジ1個をつかみ、白い箱に入れる(4・5章)。
- **3個の連続片付け**:並べ方をパターンに絞ると、手前の列では 9 回中 6 回、3個とも片付けられた。奥の列はまだできず、追加学習中(6章)。
- **最終目標(変更なし)**:日本語の音声指示で片付ける。

2. 前回(10月18日)からの改善点

仮レポートで特定した「モデルがパーツの位置を見ていない」という問題に対して、カメラとデータの両方を変えた。

項目	10月18日	10月22日
カメラ	上からの C920 のみ	C920 ＋ 手首カメラ Inno-Maker U20CAM-1080P(広角約120°、実測約29fps)
机の上のパーツ	複数が散らばる	1個だけ置く
置き場所	その都度ばらばら	マスキングテープで描いた 3×3 のマス目を順に使う
録画中の手の映り込み	あり	自動の確認画像で見つけて、その回を除外
カメラと土台	録画中にずれた回があった	固定し、位置を変えない
リセット時間	10秒	30秒(手の映り込みが 5/10 回から 1/10 回に減った)

手首カメラは、最初に M5Stack AtomS3R-CAM を試した。しかし実測が約10fpsと遅く、上のカメラと同時に使うと USB から外れたため、U20CAM に交換した。U20CAM は暗い場所で自動的にフレームレートを下げる設定があり、16fps に落ちていた。これを切る設定を録画スクリプトに組み込み、約29fps を確保した。

3. データ収集

10月22日に2カメラで 77 回録画し、品質チェックで 10 回を除外して、**67 回を使えるデータ**とした。各回の録画後に、動画の一覧画像と「各回の最初の4秒」の画像を自動で作り、手の映り込みや片付け残しを目で確認した。

録画(開始時刻)	内容	1回の長さ	録画	採用	除外した理由
18:00	1個を箱へ	20秒	7	5	2回はアームが動いていない
18:13	1個を箱へ	20秒	10	5	開始直後に手が映る
18:25	1個を箱へ	20秒	10	9	開始直後に手が映る
18:39	1個を箱へ	20秒	10	10	—
20:34	3個を続けて箱へ	45秒	10	9	開始直後に手が映る
20:54	3個を続けて箱へ	35秒	10	10	—
21:33	1個を箱へ(苦手なマス⑥⑦を集中的に)	20秒	10	10	—
22:04	3個を続けて箱へ	35秒	10	9	1個を片付け残した
合計	1個:39回、3個:28回		**77**	**67**	

- 3個のタスクでは、**箱に近い順に取る**、最後に**アームを畳んだ姿勢に戻す**、というルールを毎回守った。
- 1個のデータと3個のデータは、どちらも「机に残っていれば取りに行き、なくなれば止まる」という同じルールに従うため、混ぜて学習できる。

4. 結果1:モデルは何を見ているか

2カメラの ACT(1個のデータ29回、30,000ステップ、約2時間20分)は、アームの姿勢より画像に頼って動きを決め、**学習に使っていない配置でもスポンジの方向を狙えていた**。

入力入れ替え実験

入力の一部を別の場面のものに入れ替え、出力される関節角度の変化を測った(60場面の平均、単位は°)。

入れ替えたもの	旧 ACT-25(1カメラ) 肩・肘	新 ACT(2カメラ) 肩・肘	新 ACT 手首の回転	新 ACT グリッパー
アームの姿勢	22〜23	5〜6	4.4	2.4
上からのカメラ画像	15〜18	28〜29	18.8	7.5
手首カメラ画像	—	7〜9	26.0	10.8

- アームの姿勢への依存が、肩・肘で 22〜23° から 5〜6° に減った。画像を見て動くようになった。
- 手首カメラは、手首の回転とグリッパーの開閉に使われている。つかむ瞬間の調整という狙いどおりの役割である。

狙いのテスト

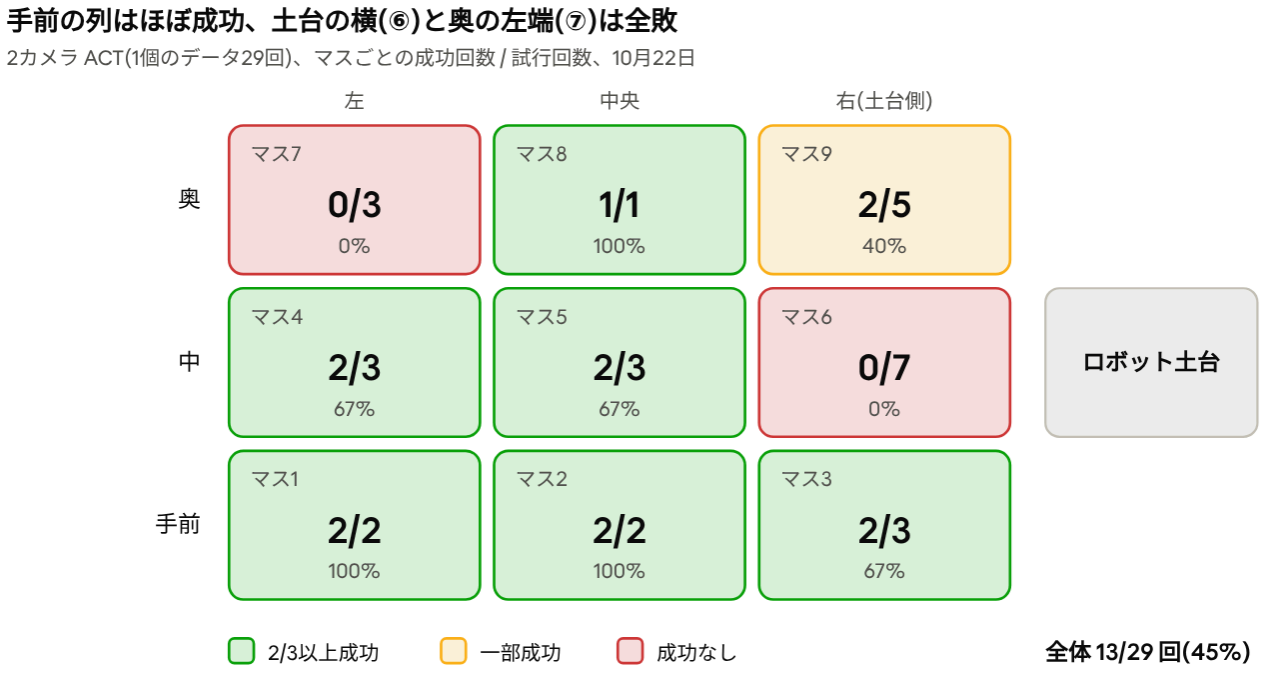
各回の最初の場面から、2秒後に肩をどの向きに回すつもりかを予測させ、お手本と比べた。

対象	お手本との平均のずれ
学習に使った5回	1.2°
学習に使っていない5回	4.2°

お手本の向きは -24〜+15° に広がっている。初めての配置でもずれは数度で、左右どちらへ取りに行くかを正しく判断できている。

5. 結果2:実機の成功率

スポンジ1個を 3×3 の各マスに置いて自律動作させ、**29回中13回(45%)、箱に入れることに成功**した。開始時はアームを畳んだ姿勢にし、1回の指令で動ける角度を 10° に制限した。



9マスの成功率 · 2カメラ ACT(29回)

手前の列(①〜③)は 6/7 回で成功した。一方、土台のすぐ横(⑥)と奥の左端(⑦)は一度も成功しなかった。⑥と⑦を除くと 13/19 回(68%)である。

6. 3個の連続片付け(10月23〜24日)

スポンジ3個を自由に並べると、1個も片付けられなかった。そこで並べ方を決まったパターンに絞ったところ、**手前の列では 9 回中 6 回、3個とも片付けられた**。

自由な並べ方で全敗した原因

1個のデータ 39 回と 3個のデータ 19 回で学習したモデル(58回分)を使った。録画開始2秒後の場面から、1〜3秒先の動きを予測させ、お手本とのずれを測った。

テストした場面	肩の回転	肩の上げ下げ	肘
3個・学習に使った並べ方	1.1°	6.0°	6.1°
3個・学習に使っていない並べ方	10.5°	26.4°	32.4°

学習で見た並べ方には対応できたが、初めての並べ方では大きくずれた。3個の位置の組み合わせは無数にあり、19 回のお手本では**並べ方を丸暗記するだけ**になったと考えられる。

対策:並べ方をパターンに絞る

並べ方を次の4パターンに限り、各パターンの中で位置を数cmずらして録画した。マス目の番号は5章の図と同じである。

パターン	置くマス	録画	採用	除外した理由
A 手前の列	①②③	10	9	時間内に終わらなかった
B 左の列	①④⑦	10	10	—
C 斜め	③⑤⑦	10	8	手の映り込み、⑦で時間切れ
D 奥の列	⑦⑧⑨	10	10	—

実機の結果(58回分のモデル、パターンの録画は未学習)

並べ方	3個とも片付けた回	箱に入った個数
自由な並べ方	0 回	0 個
手前の列(①②③)	6 / 9 回	21 / 27 個
奥の列(⑦⑧⑨)	0 / 5 回	0 / 15 個

- 手前の列では、3回連続で一発で成功した。機器の接続エラーで止まった1回は、集計から除いた。
- 奥の列では、毎回スポンジの手前で空をつかんだ。奥はアームを伸ばしきる位置で、上からのカメラでは小さく映るため、距離を見誤りやすい。人の操作でも⑦で時間切れが2回あった。
- パターン A〜C を加えた 94 回分のモデルと、さらに奥の列(D)を加えた 104 回分のモデルを学習中である。104 回分は、94 回分の学習済みモデルを出発点に追加学習して時間を短縮する。

7. 考察と次の一手

失敗が集中したのは、**お手本が少なかったマス**だった。そこで苦手なマスを狙ってデータを足し、学習し直している。

- **⑥(土台のすぐ横)0/7**:アームを大きく折りたたむ位置で、上からのカメラではアームの陰になりやすい。
- **⑦(奥の左端)0/3**:アームが最も遠くまで伸びる位置で、録画でもあまり使っていなかった。

- 苦手マスを狙って、⑥と⑦にスポンジを置いたお手本を 10 回追加した。3個のタスクでも、必ず1個を⑥・⑦・⑨のどこかに置いている。

学習中のモデル(10月24日時点)

2つのモデルを順に学習している。

1. **94回分**:1個 39 回、自由な3個 28 回、パターン A〜C 27 回。50,000ステップ。パターン A・B・C を各 5 回テストする。
2. **104回分**:94回分に奥の列(D)10 回を足し、94回分のモデルから 20,000ステップ追加学習する。奥の列が片付けられるかを確かめる。

今後の予定

- [ ] 94回分・104回分のモデルで、パターン A〜D と 9マスの成功率を評価する
- [ ] 成功率の高いパターンで、YouTube 用の本番動画を撮影する
- [ ] 音声指示(Whisper + LLM)と、言葉で動くモデル SmolVLA への移行を試す
- [ ] 動画編集、GitHub への公開、最終レポート(提出 11月2日)