Physical AI 最終課題 仮レポート

日本語の音声指示で片付けるロボットアーム(SO101×LeRobot)

Oct 19, 2026 · ID:Y-ORIHARA · 仮版(進行中の内容を含む)

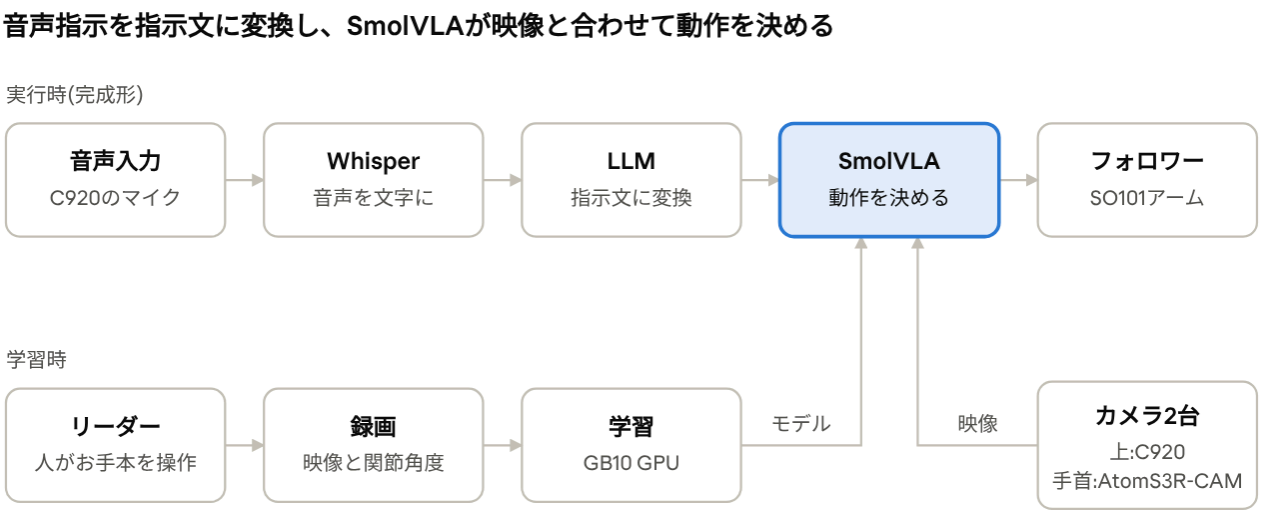
1. 課題の概要と目的

本課題では、低価格ロボットアーム SO101 に模倣学習で片付け作業を覚えさせ、最終的に**日本語の音声指示どおりに物を片付けるロボット**を実現する。10月18日時点で、セットアップから学習・実機評価までを一巡し、課題点を特定した段階である。

- **タスク(現段階)**:机の上の黒いスポンジを、つかんで白い箱に入れる。
- **最終目標**:「赤いスポンジを左の箱に入れて」のような日本語の音声指示を聞き分け、赤と黒のスポンジを指示どおりの箱へ片付ける。
- **目的**:家庭や職場の整理整頓を想定し、言葉で頼める実用的なロボットの基本形を、身近な機材とオープンソースで作ること。あわせて、データの集め方がロボットの振る舞いにどう効くかを、数値で検証する。

2. システム構成

人がリーダーアームで示したお手本を学習し、完成形では音声指示を指示文に変換して、SmolVLA がカメラ映像と関節角度から動作を決める。



システム構成 · 実行時の5段階と学習の流れ

上の段が実行時の流れ、下の段が学習の流れ。現段階では SmolVLA の代わりに ACT を使い、音声入力はまだつないでいない。

区分	構成要素	役割
ロボット	SO101 フォロワーとリーダー(各 STS3215 サーボ × 6)	作業する腕と、お手本を操作する腕
カメラ(上)	Logicool C920(640×480、30fps)	作業エリア全体を撮る
カメラ(手首)	M5Stack AtomS3R-CAM(320×240、実測10fps、電源付きUSBハブ経由)	つかむ直前の位置合わせ
計算機	NVIDIA GB10	学習と推論
ソフトウェア	LeRobot 0.6.1	録画・学習・実機での実行
モデル	ACT(現段階)、SmolVLA(最終形)	映像と関節角度から動作を予測する
音声認識	Whisper(faster-whisper)	音声を文字にする

3. 実施内容(10月18日時点)

セットアップから実機評価までを1日で一巡し、学習を2回行った。

1. **キャリブレーションの修正**:肘関節(elbow_flex)の範囲が 0〜4095 の全域になっており、値の回り込みでリーダーとフォロワーの角度が対応していなかった。両アームを再キャリブレーションし、同じ姿勢での差が全関節 ±10° 以内になることを確認した。
2. **カメラの導入**:上からのカメラ(640×480、30fps)を設置し、テレオペでの動作を確認した。
3. **データ収集**:リーダーアームで操作し、1回20秒のお手本を計 25 回記録した(5回・10回・10回の3セッション)。
4. **学習**:ACT を、品質の良い5回分(20,000ステップ、約47分)と、25回分を統合したデータ(30,000ステップ、約70分)で学習した。
5. **実機評価**:学習したモデルでフォロワーを30秒間自律動作させた。安全のため、1回の指令で動ける角度を 10° に制限した。
6. **手首カメラの追加**:評価結果を受けてグリッパーに小型カメラを取り付け、2台のカメラでの記録を確認した。

4. 結果と分析

学習の誤差は十分に下がったが、実機では**パーツのない場所へ手を伸ばした**。分析の結果、モデルはカメラを使っているものの、パーツの位置ではなく「アーム自身の姿」を主な手がかりにしていることがわかった。

モデル	学習データ	学習の誤差(最終)	お手本とのずれ	実機での様子
ACT-5	5回(品質良)	0.097	1〜2°	アームを伸ばし開閉もするが、パーツがない場所へ行く・震える
ACT-25	25回(一部に手の映り込み、カメラのずれ)	0.112	2〜3°	同様に、パーツがない場所へ行く

モデルは何を見ているか(入力入れ替え実験)

同じ場面で入力の一部だけを別の場面のものに入れ替え、出力される関節角度がどれだけ変わるかを測った(60場面の平均、単位は°)。

入れ替えたもの	ACT-5 肩の回転(pan)	ACT-5 肩・肘	ACT-25 肩の回転(pan)	ACT-25 肩・肘
カメラ画像	10.2	30〜33	8.6	15〜18
アームの姿勢	3.5	9〜10	9.8	22〜23

- 画像を入れ替えると出力が大きく変わるため、**カメラは使われている**。
- しかし、取りに行く方向を決める**肩の回転(pan)は画像にほとんど反応しない**。画像は作業の段階を読むのに使われ、パーツの位置を捉えていない。
- ACT-25 は姿勢への依存が増えた。画像にノイズ(手の映り込み、カメラのずれ)があると、モデルは画像を信用しなくなると考えられる。

5. 工夫した点

「動いたかどうか」で終わらせず、原因を数値で確かめ、次の改善につなげることを重視した。

- **モデルが何を見ているかの可視化**:入力を入れ替えて出力の変化を測る分析ツール(policy_sensitivity.py)を作り、「カメラは使うが、パーツの位置は見ていない」という失敗の正体を特定した。改善前後で同じ指標を比べられる。
- **データ品質の自動チェック**:録画ごとに動画の一覧画像を作り、関節が動いていないエピソードを自動で検出する仕組み(review.sh)を作った。これにより、「2回目の録画だけ静止している」「人の手が映り込んでいる」といった問題を、学習の前に発見できた。
- **不具合の診断**:キャリブレーションの数値、モーターの応答・電圧・温度、システムログを読んで、関節の値の回り込み、電源抓け、USB の電力不足を特定した。

- **手首カメラの追加**:分析結果から「つかむ直前の位置合わせが見えていない」と判断し、小型カメラ(M5Stack AtomS3R-CAM)をグリッパーに取り付けた。実測 10fps でも制御ループが 30Hz を保てることを確かめた。
- **作業のスクリプト化**:操作練習・カメラ確認・録画・確認・学習・自律動作をそれぞれ1行で実行できるようにし、入力ミスを防ぐチェックも入れた。繰り返しの実験を速く確実に回せる。
- **安全への配慮**:自律動作では1回の動きを 10° に制限した。震えが観察されたため、制限は緩めずにデータ改善を優先すると判断した。

6. AIの活用

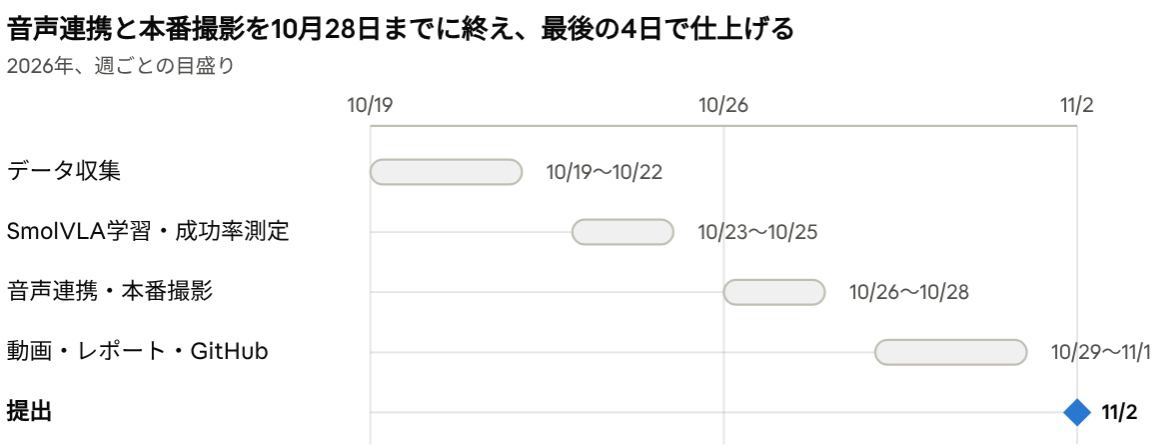
開発には AI コーディングアシスタント Claude Code を使い、実機の操作と最終判断は人が担った。

場面	AI(Claude Code)が担ったこと	人が担ったこと
不具合の診断	設定ファイル、システムログ、モーターの応答を読んで原因を特定	配線の確認、電源やケーブルの挿し直し
道具づくり	録画・確認・学習・評価のスクリプトを作成	使い勝手のフィードバック
データ収集	録画の品質チェック(手の映り込み、静止区間の発見)	リーダーアームでのお手本操作、カメラの設置
分析	モデルが何を見ているかの実験を設計・実行	実機での挙動の観察と報告
計画	評価基準から逆算したテーマ案とスケジュールの提案	テーマの決定(音声指示の片付け)

完成形では、ロボットの中にも AI を組み込む。音声認識に Whisper、指示の解釈に LLM、動作の生成に SmolVLA を使う(2章参照)。

7. 今後の計画と評価方法

11月2日の提出までに、データ収集、学習、音声連携、仕上げの4段階で進める。各段階で動くものを残すようにし、途中で止まっても作品になる順番にした。



今後の計画 · 4段階と提出日

データの集め方(4章の分析を反映)

- 机に赤と黒のスポンジを**両方**置き、指示によって取る方を変える(各指示 25〜30 回)。片方しか置かないと、指示を聞かずに「見えている物を取る」だけを覚えるため。
- 置き場所をマス目に沿って均等に変える。
- 録画中はリーダー以外に触らず、カメラ・土台・照明を固定する。

評価方法(目標は案)

評価項目	方法	目標
成功率	指示ごとに10回試し、指定した色を指定した箱に入れた回数を数える	各指示 8/10 以上
指示の聞き分け	同じ配置で指示だけを変え、取る物が変わるかを見る	取り違え 1/10 以下
画像への反応	入力入れ替え実験で、肩の回転(pan)の変化量を測る	現状の 8〜10° より大きくする
比較実験	ACT(上カメラのみ)、手首カメラ追加、SmolVLA を同じ条件で比べる	各工夫の効果を数値で示す

8. 考察とまとめ

ロボット学習の難しさは学習そのものより、「何を見せるか(データ設計)」にある。モデルはデータに含まれることを素直に覚えるため、意図した手がかりだけが映る環境づくりが成功の鍵になる。

- **学習の誤差が小さいことは、使えることを意味しない**。誤差 0.097 のモデルも、お手本の動きをなぞっているだけだった。
- **量より質**。手の映り込みやカメラのずれを含むデータを足すと、モデルは画像より姿勢に頼るようになった。
- **ばらつきは計画的に入れる**。位置を見る力をつけるには、置き場所を均等に変えたお手本が必要である。
- **失敗は数値で確かめる**。入力入れ替え実験により、勘ではなく根拠をもって次の改善策(データ設計の見直し、手首カメラ、SmolVLA)を選べた。

本レポートは仮版である。音声指示による片付けの成功率と改善前後の比較は、完成版で追記する。