Physical AI 応用編1 最終課題レポート

見て、つかんで、片付ける ── SO101 片付けロボットアーム

Oct 30, 2026 · ID:Y-ORIHARA

1. 課題の概要と目的

低価格ロボットアーム SO101 に、模倣学習で「机の上の黒いスポンジ3個を、白い箱へ片付ける」作業を覚えさせた。最終的に、同じ 112 回分のお手本で学習した2つのモデルを比べ、**Diffusion Policy ではランダムな並べ方でもスポンジの 85% を片付けられた**(ACT は 48%)。この 85% は箱に入ったスポンジの割合(60 個中 51 個)である。3個とも片付けた回の割合は 75%(20 回中 15 回、ACT は 15%)だった。

- **タスク**:スポンジ3個を、箱に近い順に1個ずつつかんで箱へ入れ、最後にアームを畳んだ姿勢に戻す。
- **目的**:家庭や職場の「片付け」を題材に、実機での模倣学習をデータ収集から評価まで通して行う。失敗の原因を分析し、講義で学んだ理論に基づいて改善する。
- **提出物**:動画(2分58秒、一部 2〜4 倍速、字幕に実時間に対する倍率を明記。https://youtu.be/zCo2obT3ASg)、コード一式(GitHub:https://github.com/tenyyprn/so101-tidyup-robot)、学習済みモデル(Hugging Face:Diffusion Policy https://huggingface.co/tenyyprn/so101-tidyup-diffusion 、比較用 ACT https://huggingface.co/tenyyprn/so101-tidyup-act)、本レポート。

2. システム構成と使用ツール

実機を使い、人がリーダーアームで示したお手本を、フォロワーアームに学習させた。

区分	使ったもの
ロボット	SO101 フォロワーとリーダー(Feetech STS3215 サーボ × 6 ずつ)
カメラ(上)	Logicool C920、640×480・30fps。作業エリア全体を見る
カメラ(手首)	Inno-Maker U20CAM-1080P(広角)、640×480・約 29fps。つかむ直前を大きく見る
計算機	NVIDIA GB10(DGX Spark)

区分	使ったもの
ソフトウェア	LeRobot 0.6.1(ACT、Diffusion Policy、SmolVLA の実装を使用)、ffmpeg
開発支援	Claude Code(Anthropic)

モデルは LeRobot 0.6.1 [1] の実装をそのまま使い、データの設計、学習の設定、評価、分析を自分で行った。

Diffusion Policy の仕組み(ノイズから行動を少しずつ作り、答えが複数ある行動の分布を表せること)は、講義資料 [8] と原論文 [3] を読んで理解し、ACT から切り替える判断と設定の参考にした。推論を速くする DDIM [4] も同様である。

配置とマスの番号

机の上にテープで 3×3 のマスを作り、①〜⑨の番号でスポンジの置き場所を決めた。箱は⑥のすぐ右、ロボットの土台はそのさらに右にある。



並べ方	マス
A 手前の列	①②③
B 左の列	①④⑦

並べ方	マス
C 斜め	③⑤⑦
D 奥の列	⑦⑧⑨
ランダム(比較に使った 4 配置)	②④⑧、③④⑧、①⑤⑦、②⑤⑨

3. 取り組みの流れ

実機で試し、失敗の原因を分析し、データかモデルを変える、をくり返した。

1. **最初の振る舞い(10/18)**:上のカメラだけの ACT は、学習の誤差が小さいのに、スポンジのない場所へ手を伸ばした。入力を入れ替える実験で、モデルが「アーム自身の姿」ばかり見ていたことを確かめた。
2. **データの作り直し(10/22)**:手首カメラを追加し、3×3 のマス目で置き場所を計画的に変えた。手の映り込みや片付け残しの回は除外した。スポンジ1個の片付けが、初めて自律で成功した(9マスで 13/29 回)。
3. **3個の連続片付け(10/23〜24)**:自由な並べ方では全敗した。並べ方をパターンに絞り、苦手な奥の列のお手本を 10 回足すと、奥の列は箱に入った割合が 0% から 87% になった。
4. **「間」をつかむ問題の発見(10/24)**:ランダムな並べ方では、ACT が2つのスポンジの間(何もない場所)をつかんだ。データを足しても残った。
5. **モデルの切り替え(10/24〜25)**:同じ 112 回分のデータで Diffusion Policy [3] を学習し(40,000 ステップ、約 6 時間)、ACT と同じ配置で比べた。

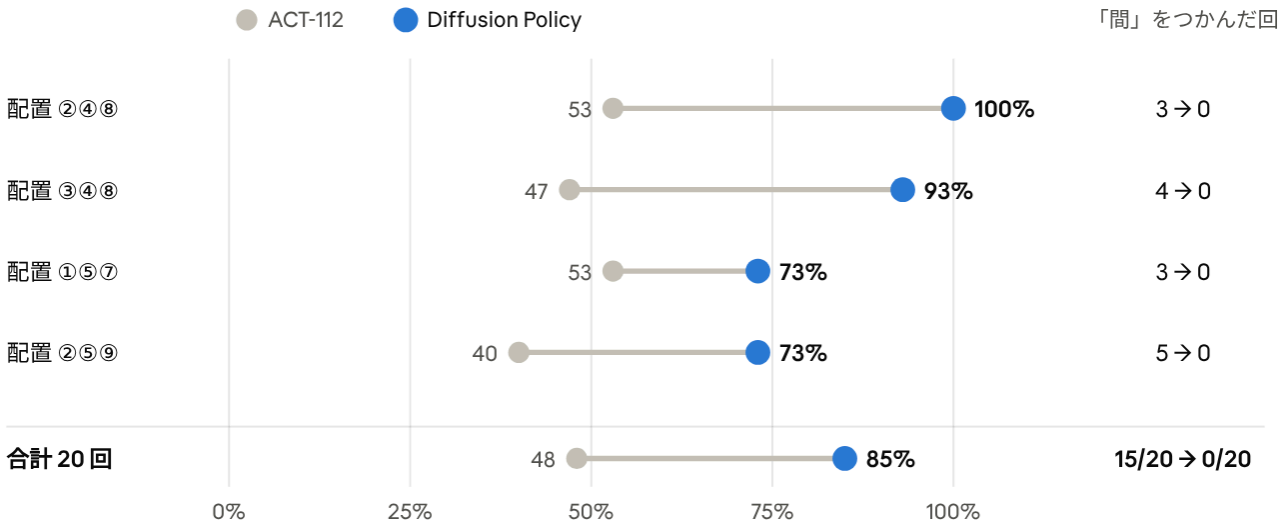
モデル	仕組み	主な設定
ACT	CVAE で行動列を学ぶ(L1 誤差 + KL 項)。実行時は潜在変数を 0 に固定し、1つの場面に1つの行動列を出す [2]	100 コマをまとめて予測・実行、94 回分のモデルから追加学習
Diffusion Policy	ノイズから行動列を少しずつ作る生成モデル [3]	画像 240×320、95% ランダム切り抜き、DDIM [4] 10 ステップ、64 コマ予測・16 コマ実行

4. 結果:ACT と Diffusion Policy の比較

同じデータ・同じランダム配置で比べると、**Diffusion Policy では「間」をつかむ失敗が 20 回中 15 回から 0 回になり、箱に入ったスポンジが 48% から 85% に増えた**。

Diffusion Policy では「間」をつかむ失敗がなくなり、片付けが増えた

箱に入ったスポンジの割合(%)と「間」をつかんだ回数、ランダム配置ごとに各 5 回



docs/eval_pick3.csv · 同じ 112 回分のデータ、同じ 4 配置 × 5 回、10月24〜25日

3個とも片付けた回は、ACT が 20 回中 3 回、Diffusion Policy が 15 回だった。定型の並べ方(手前の列)では、どちらも 5 回中 4 回、3個とも片付けた。

失敗の種類	ACT-112	Diffusion Policy
2つのスポンジの「間」をつかむ	15 回	0 回
1つのスポンジのすぐ横で空をつかみ続ける	—	2 回
時間切れ(45 秒)で残る	—	3 回

「間」をつかむ様子は、後日 ACT-112 をマス ②⑤⑨ で撮り直して記録した。グリッパーが2個の間に下りて閉じ、何も持たずに戻る。箱は空のまま、2個とも机に残る。



動画では、同じ並べ方(マス ③④⑧)で ACT と Diffusion Policy を左右に並べて見せた。ACT は1個目を箱に入れた後、残り2個の近くでつかみ損ねを約 20 秒繰り返し、最後に1個が残った。Diffusion Policy は3個とも片付けた。

また、Diffusion Policy の動作中に人の手でスポンジを動かしても、3個とも片付けた例を撮影した。ただし試したのは数回で、成功率は測っていない。

個数を増やした試験

3個のお手本だけで学習した Diffusion Policy に、4〜9個を片付けさせた。どの個数でも、全部片付けた回があった。箱には 4 個までしか入らないため、5 個以上では人が箱の中身を押し込んだり空にしたりした。

個数	試行	箱に入った数	様子
4	3 回	12 / 12	3 回とも手伝いなしで全部
5	3 回	14 / 15	2 回は箱があふれ、人が押し込んで全部。1 回は最後の 1 個の上で止まり時間切れ
6	1 回	6 / 6	途中で箱を空にした
7	1 回	7 / 7	途中で箱を空にした
8	2 回	14 / 16	1 回目は時間切れで 2 個残り、時間を延ばした 2 回目は全部

個数	試行	箱に入った数	様子
9	2回	15 / 18	1回目は時間切れで3個残り、時間を延ばした2回目は9マスすべてから全部

アームは、お手本になかった「4個目以降」も取りに行き、机の上が空になってから元の姿勢に戻った。「3個片付ける動き」を丸暗記したのではなく、カメラで残りのスポンジを見て動いていることを示す結果である。

動画の倍速について:Diffusion Policy は約0.5秒ごとに推論で止まり、その間は記録も止まる。そのため記録映像は実時間の約0.77倍に縮む。動画ではこの比を映像ごとに測り、字幕の倍速が実時間に対する倍率になるように補正した。ACT と左右に並べる場面も、両方を同じ実時間倍率で再生している。

5. 工夫した点

最終課題サンプルから発展させた点

観点	出発点[6][7]	本作品で加えたもの
タスク	1つの物をつかんで運ぶ	3個を箱に近い順に続けて片付け、最後に元の姿勢へ戻る
データ	自由に録画する	手首カメラの追加、3×3マスでの計画的な配置、品質チェックと除外、苦手な場所だけの追加(計112回)
評価	動いたかを目で見る	並べ方ごとに5回ずつ試し、全記録を CSV に残す
分析	なし	入力を入れ替えてモデルが何を見ているかを調べ、失敗の原因について講義の理論(多峰性)から仮説を立て、モデルを変えて検証
モデル	1つを使う	ACT、Diffusion Policy、SmolVLA を同じデータで比較し、理由をもって選んだ

そのほかの工夫

- **条件をそろえた比較**:ACT と Diffusion Policy を、同じデータ・同じ4つのランダム配置・同じ時間(45秒)・同じ安全制限で各20回試した。「箱に入った個数」だけでなく、「間をつかんだか」も記録した。
- **モデルが何を見ているかの分析**:画像やアームの姿勢を別の場面のものに入れ替え、出力の変化を測るツールを作った。学習の誤差だけでは分からない「丸暗記」を見つけられた。

- **データの品質管理**:録画ごとに、各回の最初の 4 秒と最後のコマの一覧画像を自動で作り、手の映り込みや片付け残しの回を除外した。
- **狙いを絞ったデータ追加**:マスごとの成功率を測り、苦手な場所だけにお手本を足した。
- **実機の安定化**:USB の電力不足には電源付きハブ、接続の切れにはシリアル番号での固定と自動リトライで対応した。
- **動画の配慮**:部屋が映る手首カメラの映像は使わず、上のカメラだけで構成した。字幕と倍速の表示は、絵コンテから自動で作る仕組みにした。

6. AI の活用

ロボットの動作そのものと、開発の進め方の両方で AI を使った。

場面	使った AI	役割
ロボットの動作	ACT、Diffusion Policy(学習と推論)	カメラ映像と関節角度から、アームの動きを決める
比較	SmolVLA(事前学習済み VLA の追加学習)[5]	「間」はつかまなかったが、学習量不足でつかめなかった
開発	Claude Code(Anthropic)	不具合の診断、スクリプトと分析ツールの作成、録画の品質チェック、実験計画、動画とレポートの下書き

実機の操作・配線・お手本の操作・実機テストの記録・最終判断は、人が行った。

7. 反省点・考察と今後

反省点

- **最初のモデルを誤差だけで信じかけた**:上のカメラだけ、お手本 5 回で学習したモデルは、誤差が小さいのに位置を見ていなかった。入力を入れ替える実験をもっと早く行うべきだった。
- **録画のルールを後から決めた**:手の映り込みやカメラのずれを含む回を、後から除外した。最初に録画の決まりごとを作れば、手戻りが少なかった。
- **SmolVLA の学習量を見積もれなかった**:30,000 ステップ × バッチ 8 では、1個もつかめなかった。
- **評価の回数が少ない**:並べ方ごとに 5 回では、差の小さい比較(定型の並べ方など)は言い切れない。
- **「手で動かす」実験は不十分**:動かした距離が小さく、アームが追いかける様子をはっきりは示せなかった。

- **箱の容量を考えていなかった**:個数を増やす試験で、箱が 5 個であふれ、人の手伝いが必要になった。
- **動画の倍速表示を後から直した**:Diffusion Policy の記録映像が実時間より縮んでいることに気づかず、最初は倍速を小さく表示していた。

考察

講義(第3回・第7回)[8]で学んだ「1つの答えを出すように学ぶ方策は、答えが複数あるお手本(多峰性)で中間に寄ることがある」という仮説を、実機で検証した。「左を取る」と「右を取る」のお手本が混ざる場面で、今回の ACT は2つの中間をつかむことが多かった(20 回中 15 回)。ACT は CVAE を使うが、実行時は潜在変数を固定するため、1つの場面には1つの行動列しか出せない。行動の分布そのものを学ぶ Diffusion Policy [3][8] では、同じデータでこの失敗が 20 回中 0 回になった。この結果は多峰性の仮説を強く支持する実験的な証拠である。ただし、ACT の内部で実際に何が起きているか(潜在変数が2つの答えを分けられていないのかなど)を断定するには、追加の分析が必要である。

- **データの設計が性能を決める**:カメラに映っているものは、すべて学習される。手の映り込みやカメラのずれを除き、置き場所を計画的に変えたことで、初めて位置を見て動けるようになった。
- **データで直せない問題は、モデルで直す**:「間」をつかむ問題は、ACT にデータを足しても残った。原因の仮説を理論から立てられたので、それを確かめられる手法を選べた。
- **残る課題**:Diffusion Policy では、時間切れ(3 回)と、手前のスポンジのすぐ横で空をつかみ続ける位置合わせのずれ(2 回)が残った。また、約 0.5 秒ごとに約 0.18 秒の推論が入り、動きが一瞬止まる。
- **今後**:つかみ直しのお手本を増やす、実行する長さと推論回数を調整する。推論の間も動きを止めないよう、推論と動作を並行して行う仕組み(非同期推論)も試したい。言葉の指示を受け取れる VLA を十分に学習させ、「赤いスポンジを左の箱へ」のような音声指示で片付けるロボットを目指す。

今後の展望

本課題の後も、次の2つの方向で取り組みを続ける。

1. **生成モデル型の方策を比べ続ける**:Diffusion Policy に加え、Transformer で行動を生成する DiT(Flow Matching)と、1〜2回の計算で行動を出す MeanFlow を試し始めている。予備的な実機試験では、記録データ上のずれが小さいモデルが、実機でも成功するとは限らなかった(DiT のずれ 1.86° は DP の 2.7° より小さいが、実機の成功は DP より低い)。また、お手本データの変え方で DP と DiT の結果が逆になり、MeanFlow は2回の計算でも実機で動きが不安定だった。今後は、開始姿勢をそろえた評価手順を固定し、データの変更を1つずつ試して原因を切り分ける。

2. **双腕に広げる**:LeRobot は SO101 の双腕構成(bi_so_follower / bi_so_leader)に対応している。アームをもう1組加え、片手で箱を押さえてもう片手で入れる、手から手へ受け渡す、といった片付け作業に挑戦する。双腕では行動が12次元になり、どちらの手から動くかという選び方も増えるため、本課題で見た「答えが複数ある」問題がより強く現れる。DP・Flow Matching・MeanFlow の違いを確かめるのに適した題材と考えている。

8. 参考文献

1. R. Cadene, S. Alibert, A. Soare, Q. Gallouédec, A. Zouitine, S. Palma, P. Kooijmans, M. Aractingi, M. Shukor, D. Aubakirova, M. Russi, F. Capuano, C. Pascal, J. Choghari, K. Meftah, M. Ellerbach, J. Moss, T. Wolf. "LeRobot: State-of-the-art Machine Learning for Real-World Robotics in Pytorch." 2024. https://github.com/huggingface/lerobot
2. T. Z. Zhao, V. Kumar, S. Levine, C. Finn. "Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware." arXiv:2304.13705, 2023. (ACT) https://arxiv.org/abs/2304.13705
3. C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, S. Song. "Diffusion Policy: Visuomotor Policy Learning via Action Diffusion." arXiv:2303.04137, 2023(RSS 2023 論文の拡張版). https://arxiv.org/abs/2303.04137
4. J. Song, C. Meng, S. Ermon. "Denoising Diffusion Implicit Models." ICLR 2021. arXiv:2010.02502. https://arxiv.org/abs/2010.02502
5. M. Shukor ほか 13 名. "SmolVLA: A Vision-Language-Action Model for Affordable and Efficient Robotics." arXiv:2506.01844, 2025. https://arxiv.org/abs/2506.01844
6. Hugging Face. "SO-101." LeRobot ドキュメント. https://huggingface.co/docs/lerobot/so101
7. npaka. "SO-101 入門 (1) - キットの入手." note, 2025年4月30日(最終課題サンプル). https://note.com/npaka/n/nfaa9db0834e5
8. Physical AI 講座 2026 応用編1 第3回・第7回 講義資料.(多峰性と Diffusion Policy の説明を読み、本作品の分析とモデル選択の参考にした)